

Extraindo Regiões de Interesses em Imagens CT Pulmonar

José Ytalo Ramon de Almeida Gonçalves / UFAL¹

¹Universidade Federal de Alagoas (UFAL)

jose.goncalves@arapiraca.ufal.br

Abstract. *Lung cancer is the type of cancer that causes the most deaths in the world and its main manifestation occurs due to the appearance of injuries lung tissue. Given its high mortality rate, this type of cancer has been increasingly studied and in an attempt to automate this process we come up against many challenges, mainly related to the of noisy details present in tomographic images. Therefore, it is extremely important to develop methods for extracting important regions of interest. Therefore, during this article we aim to develop a method for the extraction of regions of interest in pulmonary CT (computed tomography) images based on image processing techniques.*

1. Introdução

O câncer pulmonar é o tipo de câncer que mais causa mortes no mundo – sendo registrado cerca de 2.09 milhões de casos levando ao óbito mais de 1.7 milhões de pessoas no ano de 2018 [OPAS/OMS-Brasil] – e sua principal manifestação ocorre devido ao aparecimento de lesões no tecido pulmonar. Dada a sua alta taxa de mortalidade é muito importante que esse tipo de câncer seja identificado e diagnosticado o mais rápido possível. A maior dificuldade na tarefa de identificação de nódulos está em distinguir nódulos verdadeiros de outras estruturas pulmonares, como brônquios, traqueia e outros tecidos. Nesta tarefa, aspectos humanos podem interferir na identificação dos nódulos por parte dos especialistas, como cansaço, pressa, inexperiência ou outros fatores psicológicos.

Diante disso, esse tipo de câncer vem sendo cada vez mais estudado e na tentativa de automatizar o processo de detecção utilizando métodos de aprendizagem de máquina (*Machine Learning*) comumente surgiu alguns desafios, estando, em geral, relacionados com a qualidade das imagens radiográficas, sendo os principais: quantidade de imagens, problemas com ruídos e distorções; além das regiões de interesse (*ROIs*) que são relativamente pequenas e dispersas. Por isso, é de suma importância reduzir as áreas de buscas por possíveis nódulos, removendo ruídos e, consequentemente reduzindo as chances de erros de predicação feitas pelas redes de *Machine Learning*.

Diante dos problemas supracitados foram desenvolvidos formas de segmentar imagens médicas, dentre elas as chamadas *U-Net* [Brox et al. 2015] que são baseadas e Redes Neurais Convolucionais – *Convolutional Neural Network (CNN)* –, entretanto essa abordagem apresenta alta complexidade o que pode acarretar complicações em sua implementação. Então, desejando-se reduzir as interferências em relação as áreas de interesses – pulmão, este artigo visa desenvolver um método alternativo para a extração de regiões de interesses em imagens *CT (Computed Tomography)* pulmonar baseando-se em técnicas de processamento de imagens.

Este trabalho tem como intuito científico quanta a sua natureza gerar conhecimentos práticos, dirigidos e aplicado à solução de um problema específico, utilizando-se de métodos exploratórios para agrupar técnicas para tal. Isso tudo fazendo um levantamento bibliográfico de pesquisas já publicadas na área de processamento de imagem.

2. Trabalhos relacionados

Por não haver muitos trabalhos relacionados diretamente com abordagem propostas esse levantamento se fixará nos aspectos do processamento de imagem, buscando explorá-los para a formação de um método.

[Knipe and Nadrljanski] descrevem em seu artigo o funcionamento da tomografia computadorizada, um procedimento para obter imagens de diagnóstico que usa raios-X para efetuar a construção de imagens transversais (fatias) do corpo usando dados “brutos”, computadores e algoritmos complexos para a reconstrução das imagens. Este procedimento baseasse na densidade do tecido que passa pelos feixes de raio-X, devido à complexidade das estruturas corporais humana este método está suscetível a interferências casando ruído nas imagens resultantes.

[Brox et al. 2015] apresenta uma estratégia de rede de treinamento que se baseia no forte uso de aumento de dados para um uso eficiente das amostras para segmentação de imagens biomédica utilizando uma *U-Net*. Apesar de o algoritmo ter apresentado bons resultados, essa abordagem apresenta ordens de complexidade alta – necessitando obter dados, preparar e treinar uma rede neural – o que é extremamente complicado. Além de necessitar de recurso computacionais não muito viáveis, por isso durante este artigo buscaremos um método alternativos para desempenhar essa tarefa.

[Getreuer 2012] em seu artigo propões uma alternativa para um problema recorrente na segmentação de imagem – a dependência de detecção de bordar. Nesse artigo é apresentado o método inspirado no modelo *Mumford-Shah* [Wikipédia b] para aproximação de imagens, denominado *Chan-Vese*. Esse algoritmo faz a utilização de um conjunto de arestas onde é permitido haver discontinuidade e consequentemente lide com mudanças topológicas mais facilmente, sendo de enorme aplicabilidade para imagens médicas, onde geralmente há diversas falhas entre regiões vizinhas. A descrição do método demonstra ele pode ser muito eficaz para a resolução do problema proposto.

Já [Canny 1986] descreve em seu trabalho uma abordagem computacional para detecção de bordas. A detecção de bordas é uma tarefa essencial para o processamento de imagem, principalmente para a visão computação. O processo de detecção de bordas serve para simplificar a análise da imagem, reduzindo drasticamente a quantidade de dados processados, enquanto preserva a carga de trabalho e as informações sobre os objetos. Durante o processo de extração de regiões de interesse é imprescindível a utilização de detectores de bordas, sendo aplicável tanto no processo de segmentação binária quanto para determinar limites entre regiões.

3. Revisão conceitual

Durante o processo de extração das regiões será enfrentado diversos desafios, constatados a efetuar revisão bibliográfica. Dentre estes desafios destaca-se principalmente coisas relacionadas a qualidades da imagem tomográfica proporcionadas por sua forma de aquisição. Considerações sobre o levantamento:

1. **Alto índice de ruídos:** imagens CT pulmonar apresentam um alto índice de serilhamento (aliasing). Sendo necessário equalizar as bordas.
2. **Fragmentação das imagens:** imagens fragmentadas e possuem áreas de interesses relativamente pequenas.
3. **Intensidade de pixels com baixa variação:** regiões vizinha apresentam baixa variação de intensidade, o que dificulta detecção de bordas e consequentemente separação de áreas.
4. **Alta volatilidade da imagens:** a volatilidade das imagens faz com que as regiões de interesses apresentem diversos formatos e posição, o que leva ao cuidado com perda de regiões importantes..
5. **Custo computacional:** a implatação das técnicas de processamento de imagem podem ser muito custosas e apresentar lentidão em sua execução.
6. **Remoção de regiões de não interesse:**

4. Método

O processo de segmentação é constituído basicamente de duas etapas: (1) Preparação da imagem (2) extração das áreas de interesse.

4.1. Preparação da imagem

A partir da obtenção da imagem é de extrema importância a preparação dessas informações, essa atividade é denominado realce de imagens. O realce de imagens é o processo de manipular uma imagem para que suas informações estejam mais adequadas que o formato original para uma aplicação específico. Como descrito por [Gonzalez and Woods 2010] “Não existe uma teoria ”geral” de realce de imagens”, isso nos levar a conclusão de que um método útil em algum contexto não necessariamente será a melhor abordagem para outras situações.

Inicialmente preparação passa pelo processo de normalização dos dados, isso porque em geral imagens providas por *datasets* vêm em dados brutos, podendo apresentar valores negativos e fora de escala. A normalização pode ser feitas de diversas formas, porém utilizaremos a descrito pela fórmula abaixo:

$$z_i = \frac{x_i - m_{min}}{|m_{max} - m_{min}|}$$

1. m_{max} e m_{min} : valores máximo e mínimo da matriz imagem.
2. x_i : valor do pixel da i -ésima posição.
3. z_i : novo valor – entre 0 e 1 – do pixel da i -ésima posição.

Seguinte a normalização é feito transformações de intensidade na imagem, este processo tem o intuito de reduzir ruído através de alteração de pixels.

1. transformar todos os pixels com intensidades menores que 10 no valor contido na coordenada (10, 256), isso servirá para equalizar regiões distintas, principalmente nas margens da matriz.
2. preencher as primeiras 5 linhas com 0. Essa técnica servirá pra evitar com que regiões não pulmonar fiquem encostadas na borda superior, o que atrapalharia na determinabilidade de cores em relação as regiões de interesse na segmentação.
3. passagem de filtro de desfoque (blurring), para esse projeto foi escolhido filtro GaussianBlur.

Processo representado nas figuras 1a e 1b.

Fonte: Do autor




Figure 1. Preparação

4.2. Extração das regiões de interesse

Após a preparação, a imagem é segmentada com algoritmo *Chan-Vese* [Getreuer 2012]. A matriz resultante é dilata – processo onde pixels brancos sobrepõe pixels pretos – e erodida, processo inverso da dilatação. Isso fará com que brechas e serrilhamento nas bordas de regiões sejam atenuadas. As figuras 2a e 2b resumem o processo descrito. Notamos que o processo de segmentação nos retorna uma matriz binária. Além disso, é preciso durante o processo de preparação garantir que a matriz resultante tenha sempre cores determinísticas para as regiões de interesse, ou seja, nesse processo o pulmão sempre estará na cor branca.

Fonte: Do autor




Figure 2. Segmentação Chan-Vese

Em posse da matriz binária o próximo passo é utilizá-la para remover regiões de não interesse – regiões de cores pretas – e para isso será utilizado os contornos para definir os limites dessas áreas. A partir da obtenção desses limites e determinação de seus pontos extremos – mínimo e máximo, nos eixos vertical e horizontal –, figuras 3a e 3b respectivamente, será utilizado 4 pontos âncoras (marcados em amarelos e estarão a 4 pixels de distância dos pontos extremos do contorno em direção as margens da imagens) em conjunto com a matriz binária para definir a cor internas do contorno (figura 3c).

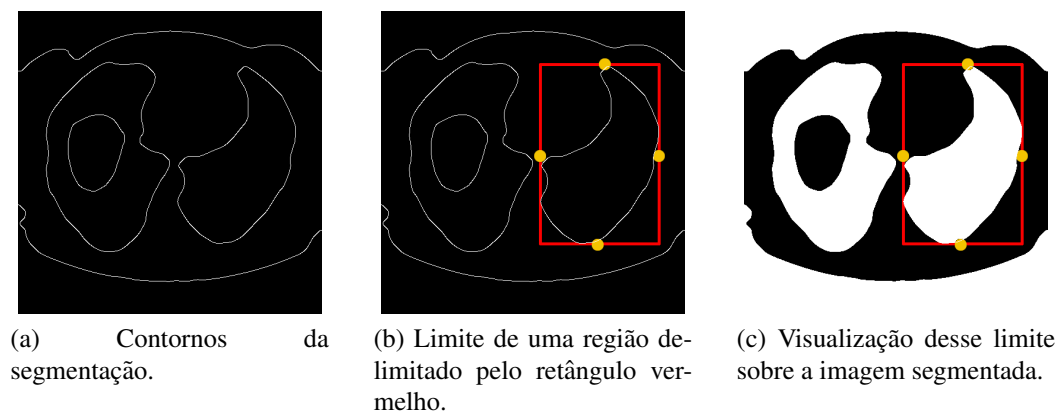


Figure 3. Manipulação através de contornos.

Fonte: Do autor

Se pelo menos 2 das 4 âncoras identificarem a cor branca significará que a parte interna do contorno é preta, logo deverá ser descartada toda essa região.

Com o processo de seleção de áreas concluído, para evitar com que a máscara segmentada fique ajustada a área e corra o risco de perder informações nas bordas é ideal que se aumente essas regiões, isso pode ser feito simplesmente com dilatação. Porém, nesse projeto esse processo será feito através do método *Convex Hull* [Wikipédia a] para aproximação de áreas em conjunto com a dilatação. Após isso, poderemos aplicar a máscara resultante sobre a imagem original e extrair as regiões de interesse, figura 4.2.

Fonte: Do autor

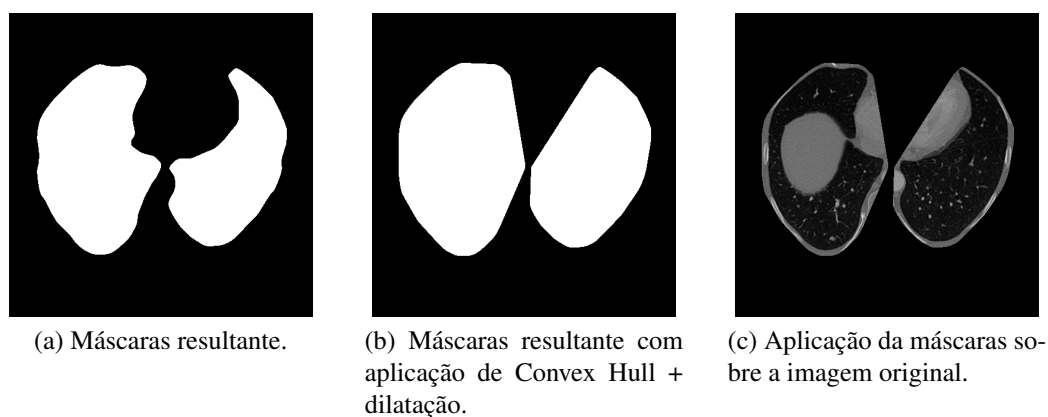


Figure 4. Máscaras resultantes e aplicação

5. Resultados

As imagens utilizado durante esse artigo foram obtidos a partir do banco de dados [LUNA16], um conjunto de dados (*dataset*) LIDC/IDRI – *The Lung Image Database Consortium image collection* – disponível publicamente.

Funções e parâmetros utilizados:

1. **Filtro GaussianBlur ([OpenCv])**: kernel=(13, 13), sigmaX=25.
2. **Chan-Vese ([Scikit-Image])**: mu=0.25, lambda1=1, lambda2=1, tol=1e-3, max-iter=200, dt=0.5, init-level-set="checkerboard".
3. **Dilatação ([OpenCv])**:(figura 2b); kernel=(MORPH-OPEN, ksize=(3, 3)), iterations=8.
4. **Erosão ([OpenCv])**:(figura 2b); kernel=(5, 5), iterations=5.
5. **Extração de Contornos ([OpenCv])**: threshold1=10, threshold2=20.
6. **Convex Hull ([OpenCv])**: (figura 4b).
7. **Dilatação ([OpenCv])**: (figura 4b); kernel=(MORPH-DILATE, ksize=(3, 3)), iterations=2.

Para constatação da validade do método foram utilizadas apenas imagens de pulmões que continuam nódulos, além de serem checadas o resultado visualmente por um ser humano. As imagens foram classificadas em 3 tipo: (Excelente) regiões extraídas perfeitamente, (Ruim) imagens com problema que impossibilitam a utilização e (Aceitável) imagens apresentam problemas na segmentação porém não afetam regiões com nódulo.

Os Testes foram realizados com 894 imagens. Sendo obtidos os seguintes resultados:

Fonte: Do autor

Classificação	Quantidade	Porcentagem (%)
Excelente	878	98.21%
Aceitável	5	0.55%
Ruim	11	1.24%
Total	894	100%

Figure 5. Tabela de resultados

6. Conclusões

A partir de todos os experimentos realizados e resultados obtidos fica claro que as técnicas de processamento digital de imagem podem ser grandes aliadas no realce de informações e para extração das regiões de interesses. Os resultados alcançados nesse projeto demonstram que esse método pode ser utilizado em um ambiente de produção ou de estudo, algo que já está acontecendo. Fica com objetivo futuro conseguir encontrar métodos mais performáticos para desempenhar algumas tarefas, algo que impossibilita hoje a utilização do processo descrito para segmentar um lote muito grande de imagens.

References

- Brox, T., Fisches, P., and Ronneberger, O. (2015). U-net: Convolutional networks for biomedical image segmentation. *Computer Science Department and BIOS Centre for Biological Signalling Studies*, 1.
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8.
- Getreuer, P. (2012). Chan–vese segmentation. *Image Processing On Line*.
- Gonzalez, R. and Woods, R. (2010). *Processamento Digital de Imagens 3ªed.* Pearson Education do Brasil.
- Knipe, H. and Nadrljanski, M. Computed tomography.
- LUNA16. luna16.grand-challenge.org.
- OPAS/OMS-Brasil. Folha informativa – câncer.
- OpenCv. <https://opencv.org/>.
- Scikit-Image. Chan-vese segmentation.
- Wikipédia, a. e. l. Convex hull.
- Wikipédia, a. e. l. Funcional de mumford-shah.